WS

Bài 1:

$$W_{xh} \cdot x_t = \begin{bmatrix} 0.5 & 0.2 \\ 0.1 & 0.4 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0.5 \\ 0.1 \end{bmatrix}$$

$$W_{hh} \cdot h_{t-1} = \begin{bmatrix} 0.3 & 0.1 \\ 0.2 & 0.5 \end{bmatrix} \begin{bmatrix} 0.5 \\ 0.2 \end{bmatrix} = \begin{bmatrix} 0.17 \\ 0.2 \end{bmatrix}.$$

$$a_t = W_{xh} \cdot x_t + W_{hh} \cdot h_{t-1} + b_h.$$

$$= \begin{bmatrix} 0.5 \\ 0.1 \end{bmatrix} + \begin{bmatrix} 0.17 \\ 0.2 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

$$= \begin{bmatrix} 0.67 \\ 0.3 \end{bmatrix}.$$

$$h_t = \tanh\left(\begin{bmatrix} 0.67 \\ 0.3 \end{bmatrix}\right) = \begin{bmatrix} \tanh(0.67) \\ \tanh(0.3) \end{bmatrix} = \begin{bmatrix} 0.585 \\ 0.2913 \end{bmatrix}$$

Bài 2:

I: RNN bắt đầu với từ này đầu tiên.

did: RNN cập nhật trạng thái từ "I" với từ "did" => bổ sung cấu trúc quá khứ

not: RNN thêm tín hiệu phủ định vào ngữ cảnh trước đó.

like: RNN kết hợp với "not" phía trước để thể hiện cảm xúc không thích

this: RNN tiếp tục cập nhật trạng thái với "this"

movie: RNN tạo hidden state cuối cùng.

- Khi đọc đến từ like, kết hợp với hidden state trước đó mang ý nghĩa phủ định sẽ biểu diễn đặc trưng phủ định của cả câu.
- Average Word2Vec lấy trung bình các vector của từ trong câu vì thế nó không xét đến thứ tự từ nên RNN coi trọng việc này để tránh mất quá nhiều thông tin.

Bài 3:

- Average Word2Vect không phân biệt được 2 câu này dựa vào thứ tự vì nó chỉ quan tâm tới giá trị trung bình.

S_1 = "dog bites man"

v_1 v_2 v_3 $\Rightarrow \frac{\vec{v_1}+\vec{v_2}+\vec{v_3}}{3} = \frac{\vec{v_3}+\vec{v_2}+\vec{v_1}}{3}$.

S_2 = "man bites dog"

v_3 v_2 v_1

- RNN sẽ cập nhật hidden state theo thứ tự.

S_1: dog → bites → man

S_2: man → bites → dog

Vì ở mỗi bước sẽ cập nhật hidden state dựa vào hidden state trước đó nên hidden state cuối sẽ khác nhau.

Bài 4:

- Khi lan truyền ngược qua nhiều timestep, gradient chứa tích các Jacobian từ các bước liên tiếp. Nếu độ lớn của các thừa số nhỏ hơn 1, nhân lặp lại sẽ khiến tích tiến về 0, tức là vanishing gradient. Khi ấy thì hiểu học từ các token ở xa khó truyền về những bước đầu chuỗi.
- Ngược lại, nếu độ lớn > 1, tích tăng nhanh gọi là exploding gradient. Việc cập nhật tham số trở nên không ổn định.
- Chuỗi càng dài thì gradient phải đi càng nhiều bước lặp, nên nguy cơ bị co nhỏ hoặc phồng to càng tăng lên. Vì vậy

Bài 5:

$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$

$= 0,2 \cdot 0,8 + 0,2 \cdot 0,5 = 0,82$.

- Khi $f_t \to 1$, $f_t \cdot C_{t-1}$ gần bằng cell state cũ, nên model có xu hướng giữ lại phần lớn ký ức cũ.
- Khi $f_t \to 0$, ký ức cũ bị giảm mạnh, cell state chủ yếu còn phần candidate được đưa vào thông qua input gate.

Scanned with CamScanner